

Diseño de eficiencia e ingeniería de prompts recurrentes

Caso: el reporte mensual de consultas de Agencia Norte

Estudiante	Nombre y apellido (ejemplo)
Curso	AI Automation · Coderhouse
Modelo elegido	Claude Sonnet 5
Precios	Página oficial de precios de Claude, verificados el 28/09/2026

Este es un documento de ejemplo. Muestra cómo puede verse tu entrega. Tu PDF tiene que ser sobre tu propio caso (reseñas, contratos, facturas, consultas: algo con mucho volumen que pueda esperar), pero con estas cuatro piezas.

El caso

Agencia Norte es una agencia chica de diseño web y marketing digital. Recibe unas **600 consultas por mes** por correo. Paula, la directora, quiere un **reporte mensual**: qué servicios pide la gente, con qué presupuesto y con qué urgencia. Lo revisa el lunes, así que no es urgente.

Voy a usar Claude para clasificar cada consulta. Como son muchas y pueden esperar, diseño el proceso para gastar lo mínimo: una plantilla con la parte fija arriba (Pieza 1), un lote que se procesa de un viernes a un sábado (Pieza 2) y el caché de la parte fija (Pieza 3). La matriz de la Pieza 4 muestra cuánto ahorra cada decisión.

Pieza	Qué muestra	Criterio de la rúbrica
1	La plantilla de prompt: rol, pensar paso a paso y variables {{ }}	Ingeniería de prompts avanzada (40%)
2	El flujo por lotes con sus tres marcas de tiempo	Modelado del flujo por lotes (25%)
3	El bloque de prefijo con cache_control	Ahorro por Prompt Caching (15%)
4	La matriz de costos: Batch y Caching en filas separadas	Ahorro por Batches (20%) y Caching

La plantilla tiene dos partes. **Arriba, todo lo que es igual en las 600 consultas:** el rol, el objetivo, el catálogo, las reglas, los ejemplos y el formato. **Abajo, lo que cambia:** tres variables entre `{{ }}`. La instrucción de pensar paso a paso (resaltada) está en el bloque CÓMO RESPONDER, y el razonamiento va como primer campo del JSON.

PARTE FIJA · va primero · es la que se guarda en el caché (2.261 tokens, medidos en el Playground de Claude)

Actuá como analista comercial senior de Agencia Norte, una agencia chica de diseño web y marketing digital de Buenos Aires.

Tu objetivo: leer una consulta que un posible cliente envió por correo y clasificarla para el reporte mensual que revisa la directora. El reporte responde tres preguntas: qué servicios pide la gente, con qué presupuesto y con qué urgencia.

CATÁLOGO DE SERVICIOS DE AGENCIA NORTE

- Landing page: desde USD 400. Plazo: 1 semana. Una sola página para una campaña, un lanzamiento o un formulario.
- Sitio web institucional: desde USD 1.200. Plazo: 4 semanas. Varias secciones: inicio, servicios, equipo, contacto.
- Tienda online: desde USD 2.500. Plazo: 6 semanas. Catálogo de productos, carrito y pagos.
- Gestión de redes sociales: USD 300 por mes. Publicaciones, diseño de piezas y respuesta de mensajes.
- Campañas de anuncios: USD 250 por mes más la inversión en pauta. Anuncios en redes y buscadores.

INFORMACIÓN GENERAL DE LA AGENCIA

- Atendemos de lunes a viernes, de 9 a 18 horas (hora de Argentina).
- Trabajamos con clientes de todo el país, de forma remota.
- Forma de pago: 50% al comenzar y 50% al entregar, por transferencia bancaria.
- Todos los proyectos web incluyen dos rondas de cambios y un mes de soporte.
- No hacemos aplicaciones móviles, sistemas a medida ni videojuegos. Si piden algo de esto, el servicio es "Otro".
- Los precios del catálogo son de referencia: el presupuesto final depende del alcance.

CÓMO SUELEN ESCRIBIR LOS CLIENTES

- "Página", "web" o "sitio" puede ser landing o sitio institucional: si habla de una sola página o de una campaña, es Landing page; si menciona varias secciones, es Sitio web institucional.
- "Vender por internet", "carrito", "e-commerce" o "catálogo con pagos" es Tienda online.
- "Instagram", "posteos" o "community manager" es Gestión de redes sociales.
- "Publicidad", "anuncios", "Google Ads" o "pauta" es Campañas de anuncios.
- Si el monto está en pesos, no lo conviertas: usá null en "presupuesto_usd" y mencioná el monto en el resumen.

REGLAS DE CLASIFICACIÓN

1. "servicio": elegí UNO del catálogo. Si pide dos, elegí el principal (el que más presupuesto implica). Si no encaja en ninguno, usá "Otro".
2. "presupuesto_usd": solo si el cliente menciona un monto. Convertí a número entero en dólares (sin símbolos ni puntos). Si no menciona monto, usá null. No lo estimes vos.
3. "prioridad": un número entero del 1 al 5.
 - 5 = quiere avanzar ya o tiene una fecha límite en los próximos 3 días.
 - 3 = interés concreto, sin urgencia.
 - 1 = solo está averiguando, sin fecha ni presupuesto.
4. "resumen": qué necesita, en 10 palabras como máximo.
5. Si la consulta no es de un posible cliente (spam, proveedores, respuestas automáticas), usá servicio "Otro", prioridad 1 y resumen "No es una consulta comercial".

EJEMPLOS RESUELTOS

Consulta: "Necesitamos una landing para el lanzamiento del sábado, tengo presupuesto aprobado. ¿Me llaman hoy?"

Respuesta: {"razonamiento": "Pide una sola página para un lanzamiento con fecha en 3 días.", "servicio": "Landing page", "presupuesto_usd": null, "prioridad": 5, "resumen": "Landing para lanzamiento del sábado, presupuesto aprobado"}

Consulta: "¿Cuánto sale el manejo mensual de redes? Estoy armando el presupuesto del año que viene."

Respuesta: {"razonamiento": "Pregunta precio de redes para el año próximo, sin urgencia ni monto.", "servicio": "Gestión de redes sociales", "presupuesto_usd": null, "prioridad": 1, "resumen": "Averigua precio de redes para el año próximo"}

Consulta: "Queremos vender online nuestros productos. Tenemos unos 3000 dólares. ¿Qué plazos manejan?"

Respuesta: {"razonamiento": "Quiere vender online con monto mencionado de 3000 dólares, sin fecha.", "servicio": "Tienda online", "presupuesto_usd": 3000, "prioridad": 3, "resumen": "Tienda online con presupuesto de 3000 dólares"}

Consulta: "Somos un estudio contable y queremos una web con quiénes somos, servicios y contacto. Nos gustaría tenerla para fin de mes."

Respuesta: {"razonamiento": "Menciona varias secciones y una fecha a fin de mes, sin monto.", "servicio": "Sitio web institucional", "presupuesto_usd": null, "prioridad": 3, "resumen": "Web institucional para estudio contable, a fin de mes"}

Consulta: "Hola, somos proveedores de hosting y queremos ofrecerles un plan especial para agencias."

Respuesta: {"razonamiento": "Es un proveedor ofreciendo un servicio, no un posible cliente.", "servicio": "Otro", "presupuesto_usd": null, "prioridad": 1, "resumen": "No es una consulta comercial"}

CÓMO RESPONDER

Pensá paso a paso antes de dar la conclusión: primero identifiqué qué pide el cliente, después busqué el servicio en el catálogo, después revisé si menciona monto y fecha, y recién al final decidí la prioridad. Escribí ese razonamiento en una o dos oraciones dentro del campo "razonamiento", que va primero.

Devolvé exclusivamente un objeto JSON con estas claves, en este orden: "razonamiento", "servicio", "presupuesto_usd", "prioridad", "resumen".

No agregues texto fuera del JSON. No inventes datos que no estén en la consulta.

PARTE VARIABLE · va después · cambia en cada una de las 600 consultas (unos 177 tokens en promedio)

Remitente: {{remitente}}

Fecha: {{fecha}}

Consulta:

{{consulta}}

Por qué este orden

El caché guarda el principio del prompt hasta donde lo marco. Si pusiera {{consulta}} en el medio de las reglas, todo lo que viene después dejaría de ser idéntico entre consultas y el caché no serviría.

Respuesta esperada con la consulta de Martina (una landing para el sábado, presupuesto aprobado):

```
{"razonamiento": "Pide una landing con fecha límite el sábado y presupuesto aprobado.",  
  "servicio": "Landing page", "presupuesto_usd": null, "prioridad": 5,  
  "resumen": "Landing para el sábado, presupuesto aprobado"}
```

Pieza 2 · El flujo por lotes y sus tres marcas de tiempo

Rúbrica: 25%

Las 600 consultas del mes se mandan juntas a la Message Batches API. Anthropic las procesa en hasta 24 horas y cobra la mitad.

Marca	Cuándo	Qué pasa
(a) t0 · Envío del lote	Viernes 22:00	Un solo envío a POST /v1/messages/batches con las 600 consultas (una solicitud por consulta, cada una con su custom_id). La respuesta es inmediata: un ID de lote y el estado in_progress.
(b) Ventana de procesamiento	Hasta 24 horas (la mayoría termina en menos de 1 hora)	Todavía no hay resultados. Es la espera que acepto a cambio del 50% de descuento.
(c) t1 · Recuperación	Sábado	Consulto el lote hasta que el estado es ended y descargo los 600 resultados juntos (quedan disponibles 29 días). Los resultados pueden venir en otro orden: los ubico por su custom_id.
Uso del resultado	Lunes 9:00	El reporte mensual está listo para Paula.

Por qué mi caso tolera la espera: el reporte se revisa el lunes y las consultas se procesan el viernes a la noche: nadie espera la respuesta en pantalla. Si necesitara respuesta en segundos, como al contestarle a una clienta, Batch no aplicaría y usaría la API estándar.

Cada solicitud dentro del lote

```
{
  "custom_id": "consulta-001",
  "params": { el mismo pedido de la Pieza 3, con los datos de la consulta 001 }
}
```

Beneficio económico del lote: el 50% se aplica sobre la entrada y la salida. El reporte pasa de US\$ 3,74 a US\$ 1,87 (la cuenta está en la Pieza 4).

La marca cache_control va al final de la parte fija: todo lo que está antes se guarda en el caché; lo que viene después, en messages, cambia en cada consulta.

```
{
  "model": "claude-sonnet-5",
  "max_tokens": 1024,
  "system": [
    {
      "type": "text",
      "text": "Actuá como analista comercial senior de Agencia Norte... (toda la PARTE FIJA de la Pieza 1: rol, catálogo, reglas, ejemplos y pensar paso a paso)",
      "cache_control": { "type": "ephemeral", "ttl": "1h" }
    }
  ],
  "messages": [
    { "role": "user",
      "content": "Remitente: {{remitente}}\nFecha: {{fecha}}\nConsulta: \n{{consulta}}" }
  ]
}
```

Decisión	Justificación
Qué bloque	Toda la parte fija de la Pieza 1. Es idéntica en las 600 consultas: no tiene ninguna variable.
Supera el mínimo	Tiene 2.261 tokens. El mínimo cacheable de Claude Sonnet 5 es 1.024 tokens.
Cuánto dura (TTL)	1 hora ("ttl": "1h"), porque va dentro de un lote y el lote puede tardar más de 5 minutos. Si las consultas fueran en tiempo real y seguidas, alcanzaría con 5 minutos.

Supuestos

Dato	Valor	De dónde sale
Consultas por mes	600	Volumen de Agencia Norte
Parte fija (prefijo)	2.261 tokens	Medido en el Playground de Claude
Parte variable	177 tokens en promedio	Medido con dos consultas reales
Salida	135 tokens en promedio	Medido con dos consultas reales
Precios de Claude Sonnet 5 (US\$ por millón de tokens)	Entrada 2 · Salida 10 · Escritura de caché 5 min 2,50 · Escritura 1 h 4 · Lectura de caché 0,20	Página oficial de precios, 28/09/2026

La matriz

Fila	La cuenta	Resultado
Base, sin optimizar	Entrada: $600 \times (2.261 + 177) = 1.462.800$ tokens x US\$ 2 por millón = US\$ 2,93 Salida: $600 \times 135 = 81.000$ tokens x US\$ 10 por millón = US\$ 0,81	US\$ 3,74
Ahorro por Message Batches (-50%)	El lote cobra la mitad de la entrada y de la salida: US\$ 3,74 x 50%	- US\$ 1,87
Ahorro por Prompt Caching (-90% sobre el prefijo)	Prefijo sin caché: $600 \times 2.261 = 1.356.600$ tokens x US\$ 2 = US\$ 2,71 Prefijo con caché: 1 escritura ($2.261 \times \text{US\$ } 2,50$) + 599 lecturas ($1.354.339 \times \text{US\$ } 0,20$) = US\$ 0,28	- US\$ 2,44
Los dos combinados	En orden: primero el caché (de 1 hora, por el lote) y después el 50% del lote sobre ese resultado	US\$ 0,65 (82,6% menos)

Los dos ahorros no se suman. Actúan sobre bases que se solapan: el prefijo está adentro de la entrada del lote. Por eso no es $50\% + 90\% = 140\%$ de ahorro (sería imposible): se aplican uno después del otro, como dos cupones en el súper. Y lo que baja es el **costo por token**, no la cantidad de tokens: las 600 consultas siguen teniendo los mismos tokens.

Aclaración: dentro de un lote, los aciertos del caché no están garantizados. El costo real del mes queda entre US\$ 0,65 (todos los aciertos) y US\$ 1,87 (solo el lote).